Модуль для загрузки .raw файлов по временному диапазону из CSV

5 марта 2026 г.

Содержание

1 Введение **2**

2 Требования **2**

3 Структура URL на сервере **2**

4 Формат CSV-файла **3**

5 Основная функция **3**
- 5.1 Параметры 4
- 5.2 Возвращаемое значение 4

6 Примеры использования **4**
- 6.1 Одноразовое скачивание всех файлов за период 4
- 6.2 Скачивание только первых 10 файлов 5
- 6.3 Непрерывный мониторинг новых файлов 5

7 Примечания и ограничения **5**

8 Описание внутренних функций (для разработчиков) **6**

9 Лицензия **6**

1 Введение

Данный модуль предназначен для автоматической загрузки файлов в формате `.raw` с удалённого HTTP-сервера. Файлы организованы в иерархическую структуру каталогов: год, затем подпапка вида `YYMMDD-HH` (дата и час в UTC), внутри которой лежат файлы с именем `_<timestamp>.13.raw`, где `<timestamp>` — целое число (секунды с начала эпохи UNIX).

Пользователь предоставляет CSV-файл с временными метками событий. Модуль:

- читает метки из указанной колонки;
- применяет коррекцию часового пояса (если задано смещение);
- определяет минимальный и максимальный timestamp;
- находит все подпапки, которые могут содержать файлы из этого диапазона;
- собирает URL всех подходящих файлов;
- скачивает их с поддержкой докачки (resume);
- при необходимости может работать в режиме мониторинга, периодически проверяя появление новых файлов.

2 Требования

Для работы модуля необходимы:

- Python 3.6 или выше;
- библиотека `requests`.

Установка зависимостей:

```
pip install requests
```

Листинг 1: Установка requests

3 Структура URL на сервере

Базовый URL должен указывать на корневой каталог данных, например:

`http://example.com/data/`

Внутри него ожидается наличие подкаталога с именем года (например, `2026/`), а в нём — подкаталоги вида `YYMMDD-HH` (например, `260303-16` для 3 марта 2026 года, 16 часов UTC). В этих подкаталогах находятся файлы с именем `_<timestamp>.13.raw`, где `<timestamp>` — UNIX timestamp (целое число).

Пример полного пути:

`http://example.com/data/2026/260303-16/_1772545747.13.raw`

4 Формат CSV-файла

CSV-файл должен содержать временные метки в одном из следующих форматов (предполагается, что метки указаны в локальном времени, возможно, со смещением относительно UTC):

- `2026-03-03T14:29:18.842930` (ISO с микросекундами);
- `2026-03-03 14:29:18.842930` (с пробелом);
- `2026-03-03T14:29:18`;
- `2026-03-03 14:29:18`.

Первая строка — заголовок. Название колонки с метками может быть любым, его индекс или имя передаётся в функцию.

5 Основная функция

```python
def download_files_by_range(
    csv_path: str,
    base_url: str,
    year: str,
    timestamp_column: Union[int, str] = 0,
    time_offset_seconds: float = 0.0,
    download_dir: str = "downloads",
    resume: bool = True,
    max_files: Optional[int] = None,
    monitor: bool = False,
    interval: int = 60
) -> List[str]
```

Листинг 2: Сигнатура основной функции

5.1 Параметры

Параметр	Тип	Описание
`csv_path`	`str`	Путь к CSV-файлу с временными метками.
`base_url`	`str`	Базовый URL сервера (например, `"http://example.com/data/"`).
`year`	`str`	Год, для которого осуществляется поиск (например, `"2026"`).
`timestamp_column`	`Union[int, str]`	Индекс колонки (целое число) или её название (строка), содержащей временные метки. По умолчанию `0`.
`time_offset_seconds`	`float`	Смещение, которое нужно прибавить к локальным меткам из CSV, чтобы получить UTC. Например, для UTC+3 укажите `10800`. По умолчанию `0.0`.
`download_dir`	`str`	Каталог для сохранения скачанных файлов (будет создан при необходимости).
`resume`	`bool`	Если `True`, используется докачка (продолжение прерванных загрузок).
`max_files`	`Optional[int]`	Максимальное количество файлов для скачивания (если `None`, скачиваются все найденные).
`monitor`	`bool`	Если `True`, включает режим непрерывного мониторинга (см. раздел 6.3).
`interval`	`int`	Интервал между проверками в секундах (используется только при `monitor=True`).

5.2 Возвращаемое значение

- При `monitor=False` возвращает список путей к скачанным файлам.
- При `monitor=True` запускает бесконечный цикл и не возвращает управления (завершается по `Ctrl+C`).

6 Примеры использования

6.1 Одноразовое скачивание всех файлов за период

```python
from raw_downloader import download_files_by_range

downloaded = download_files_by_range(
    csv_path="log.csv",
    base_url="http://example.com/data/",
    year="2026",
    timestamp_column="timestamp",
    time_offset_seconds=10800,          # UTC+3
    download_dir="./raw_data",
    resume=True,
    max_files=None,
    monitor=False
```

```
)

print(f"                    ␣{len(downloaded)}␣                  ")
```

Листинг 3: Пример с коррекцией часового пояса

6.2 Скачивание только первых 10 файлов

```
downloaded = download_files_by_range(
    csv_path="log.csv",
    base_url="http://example.com/data/",
    year="2026",
    timestamp_column=0,                    #

    time_offset_seconds=0,                  #
    download_dir="./raw_data",
    resume=True,
    max_files=10,
    monitor=False
)
```

Листинг 4: Ограничение количества файлов

6.3 Непрерывный мониторинг новых файлов

```
download_files_by_range(
    csv_path="log.csv",
    base_url="http://example.com/data/",
    year="2026",
    timestamp_column="timestamp",
    time_offset_seconds=10800,
    download_dir="./raw_data",
    resume=True,
    monitor=True,
    interval=60    #
)
```

Листинг 5: Мониторинг

7 Примечания и ограничения

1. **Индексация**. Поиск файлов основан на предположении, что на сервере включена опция `Indexes` (отображение списка файлов в виде HTML-страницы). Если индексация отключена, метод не сработает.

2. **Формат подпапок**. Имена подпапок должны строго соответствовать шаблону `YYMMDD-HH`. Если сервер использует другую схему, потребуется модификация функций `timestamp_to_subfolder` и `is_subfolder_relevant`.

3. **Часовой пояс**. Все внутренние операции выполняются в UTC. Параметр `time_offset_secon` позволяет привести локальные метки из CSV к UTC.

4. **Докачка**. Функция `resume_download` использует заголовок `Range`. Если сервер не поддерживает частичную загрузку, файл будет загружен с начала.

5. **Производительность**. При большом диапазоне и множестве подпапок процесс поиска может занять некоторое время из-за последовательных запросов к каждой подпапке.

8 Описание внутренних функций (для разработчиков)

Модуль содержит несколько вспомогательных функций, которые могут быть полезны при расширении функциональности:

- `parse_timestamp(ts_str)` – преобразует строку в UNIX timestamp.
- `read_csv_timestamps(csv_path, timestamp_column, time_offset_seconds)` – читает метки из CSV с коррекцией.
- `get_timestamp_range(timestamps)` – вычисляет мин/макс.
- `timestamp_to_subfolder(ts)` – генерирует имя подпапки по UTC.
- `filename_to_timestamp(filename)` – извлекает timestamp из имени файла.
- `check_file_exists(url)` – проверяет существование файла HEAD-запросом.
- `resume_download(url, download_dir)` – скачивает с докачкой.
- `get_subfolders_in_year(base_url, year)` – получает список подпапок года.
- `is_subfolder_relevant(subfolder, min_ts, max_ts)` – проверяет, попадает ли подпапка в диапазон.
- `find_raw_files_on_page(url)` – ищет .raw файлы на странице.
- `find_files_in_range(base_url, year, min_ts, max_ts)` – основной поиск файлов.

9 Лицензия

Модуль предоставляется "как есть"без каких-либо гарантий. Вы можете свободно использовать и модифицировать его под свои нужды.